

Segmentación Automática de Nódulos Pulmonares en Tomografías Computarizadas mediante Arquitecturas de Aprendizaje Profundo

Maximiliano Morales,

Escuela de Ingeniería Civil Biomédica, Universidad de Valparaíso

Asignatura: Inteligencia Artificial / Procesamiento de Imágenes Médicas (BME513)

Resumen—El cáncer de pulmón presenta una de las mayores tasas de mortalidad oncológica a nivel mundial, siendo la detección temprana mediante Tomografías Computarizadas (CT) el factor determinante en el pronóstico del paciente. En el flujo clínico, la delimitación manual de lesiones sospechosas por parte del radiólogo es un proceso exhaustivo y propenso a variabilidad inter-observador. Este trabajo implementa y evalúa un sistema de segmentación automatizado basado en la arquitectura de aprendizaje profundo U-Net clásica, utilizando matrices bidimensionales provenientes del consorcio internacional *Medical Segmentation Decathlon (Task06_Lung)*. Para mitigar el severo desbalance de clases biológico identificado en las imágenes, donde el tejido tumoral representa únicamente el 0.7370 % del volumen espacial total, se integró la función de pérdida *Dice Loss* en el proceso de optimización. Tras un entrenamiento acelerado por hardware empleando una arquitectura GPU, el modelo propuesto alcanzó un *Dice Score* de 0.8210 en un conjunto de prueba independiente con 233 imágenes ocultas, superando el umbral de aceptación clínica estándar del 80 %. Adicionalmente, se contrastaron los resultados frente a la variante *Attention U-Net*, la cual obtuvo un desempeño de 0.6748 debido a limitaciones en la convergencia temporal bajo recursos acotados. Los resultados validan la robustez y eficiencia computacional de la arquitectura U-Net base para el entorno de asistencia al diagnóstico clínico.

Index Terms—Segmentación semántica, U-Net, Tomografía Computarizada, Dice Loss, Inteligencia Artificial Biomédica.

I. INTRODUCCIÓN

EL carcinoma pulmonar se posiciona de forma consistente como una de las patologías malignas con mayor tasa de letalidad y menor tasa de supervivencia a cinco años si no es diagnosticada en etapas tempranas. En la práctica médica moderna, el mecanismo principal de tamizaje y caracterización anatómica de lesiones sospechosas es la Tomografía Computarizada (CT) de tórax. Los equipos de adquisición actuales generan volúmenes tridimensionales densos compuestos por cientos de cortes axiales bidimensionales por cada paciente. La inspección e interpretación manual de esta vasta cantidad de información digital impone una carga de trabajo cognitiva crítica sobre los departamentos de radiología, incrementando la probabilidad de omitir micro-nódulos debido al agotamiento visual y a la fatiga acumulada.

Desde la perspectiva del procesamiento de imágenes médicas, el desafío de la segmentación es multifactorial. Los nódulos pulmonares presentan un tamaño milimétrico en etapas tempranas y sus propiedades de atenuación radiológica

(expresadas en Unidades Hounsfield) suelen solaparse significativamente con estructuras anatómicas adyacentes sanas, tales como vasos sanguíneos, bronquiolos densos, el parénquima pulmonar circundante o la pleura. Consecuentemente, las técnicas clásicas de procesamiento digital de señales e imágenes basadas estrictamente en umbralización (*thresholding*) o detectores de bordes lineales resultan insuficientes, ya que carecen de la sensibilidad espacial y de contexto anatómico necesario para aislar la morfología tumoral sin generar falsos positivos masivos. Esto justifica la necesidad de transicionar hacia modelos de aprendizaje profundo con capacidades de representación jerárquica no lineal.

I-A. Descripción de los Datos Utilizados

Para el desarrollo de este proyecto se utilizó la base de datos abierta proveniente del consorcio internacional *Medical Segmentation Decathlon*, específicamente el subconjunto *Task06_Lung* [1]. El conjunto de datos original está constituido por tomografías de tórax de pacientes con nódulos pulmonares validados y segmentados manualmente por radiólogos expertos (constituyendo el *Ground Truth* o estándar de referencia).

Para optimizar el flujo de procesamiento en los entornos de ejecución, el volumen tridimensional original fue descompuesto y estructurado en un formato de matrices bidimensionales indexadas en archivos estandarizados de NumPy (.npy). El conjunto de datos total quedó conformado por un universo de 1,547 imágenes útiles de entrenamiento, validación y prueba, con una resolución espacial fija de 256×256 píxeles.

Durante la fase de análisis exploratorio de datos (EDA), se identificó analíticamente un desafío computacional crítico: la clase de interés (el tejido tumoral) representa únicamente el 0,7370 % del volumen total de píxeles del dataset, quedando el 99,2630 % restante asignado a la clase de fondo (aire, hueso y tejido blando sano). Este fenómeno introduce un escenario de desbalance severo de clases que guió de forma directa las decisiones de diseño de las funciones de costo computacionales, impidiendo el uso de funciones tradicionales como la entropía cruzada o métricas sesgadas como la precisión global (*accuracy*) para guiar adecuadamente el aprendizaje del gradiente de la red.

II. DESCRIPCIÓN DE LA SOLUCIÓN PROPUESTA

Para abordar la problemática de la segmentación automática de nódulos pulmonares, se implementó una arquitectura basada

en la red convolucional U-Net clásica [2]. Esta topografía de red destaca en el procesamiento de señales e imágenes biomédicas por su diseño simétrico y su capacidad para operar eficientemente con conjuntos de datos acotados. La estructura se divide conceptualmente en tres componentes fundamentales:

1. **Ruta de Contracción (Encoder):** Actúa como un extractor jerárquico de características espaciales. A través de la aplicación sucesiva de operaciones de convolución con mapas de filtros y capas de submuestreo (*Max Pooling*), el *Encoder* reduce progresivamente la resolución de la imagen de entrada mientras incrementa la profundidad de los canales de características. Este proceso permite compactar la información y capturar el contexto global de la anatomía torácica (identificando las estructuras presentes).
2. **Cuello de Botella (Bottleneck):** Es la zona de transición central de la red. Conecta las rutas de contracción y expansión mediante bloques convolucionales densos, forzando a la red a generar una representación latente abstracta de la geometría del nódulo antes de iniciar la reconstrucción espacial.
3. **Ruta de Expansión (Decoder):** Tiene como objetivo restituir las dimensiones espaciales originales de la tomografía a partir de la representación latente. Utiliza operaciones de convolución traspuesta (o *Up-sampling*) para proyectar los mapas de características abstractos de vuelta a la resolución nativa (256×256 píxeles), permitiendo finalmente asignar una clasificación binaria probabilística a nivel de píxel (tejido tumoral versus parénquima sano).

II-A. Conexiones de Salto (Skip Connections)

Un elemento arquitectónico crítico de la U-Net son las *Skip Connections* (conexiones de salto) directas entre los niveles del *Encoder* y el *Decoder*. Durante la etapa de contracción, las operaciones de submuestreo descartan inevitablemente información de alta frecuencia espacial, degradando la definición de las fronteras anatómicas.

Las conexiones de salto solucionan esta pérdida concatenando los mapas de características de alta resolución preservados en el *Encoder* con los mapas interpolados en el *Decoder* antes de cada bloque de doble convolución. Esta transferencia directa de información contextual es vital para recuperar los bordes precisos del micro-nódulo y garantizar una delimitación geométrica fina del tumor.

II-B. Formulación Matemática de la Función de Pérdida

Como se evidenció en la caracterización de los datos, el desbalance extremo de clases impediría el uso de la entropía cruzada convencional, ya que la red convergería de forma trivial hacia un mínimo local donde clasifica todos los píxeles como fondo (sano). Para resolver este desbalance biológico, se seleccionó y programó de forma nativa la función de pérdida *Dice Loss*.

La función *Dice Loss* (L_{Dice}) se deriva directamente del Coeficiente de Similitud de Dice (*DSC*), una métrica matemática empleada para cuantificar el grado de solapamiento espacial entre dos conjuntos espaciales binarios. Formalmente, se define mediante la ecuación:

$$DSC = \frac{2|X \cap Y|}{|X| + |Y| + \epsilon} \quad (1)$$

Donde $X \in [0, 1]^N$ representa el vector aplanado de intensidades continuas probabilísticas predichas por la función de activación sigmoide de la capa de salida de la red, e $Y \in \{0, 1\}^N$ denota la máscara binaria real de referencia (*Ground Truth*) delimitada por el radiólogo. El término ϵ constituye un factor de suavizado matemático infinitesimal ($\epsilon = 1 \times 10^{-6}$) incorporado para prevenir indeterminaciones por división por cero en escenarios donde tanto el tejido tumoral real como el predicho estén ausentes en el corte axial evaluado.

Puesto que los algoritmos de optimización basados en gradiente estocástico buscan la minimización de un escalar de error, la función de pérdida se formula de manera complementaria al coeficiente de similitud:

$$L_{Dice} = 1 - DSC = 1 - \frac{2 \sum_{i=1}^N x_i y_i}{\sum_{i=1}^N x_i + \sum_{i=1}^N y_i + \epsilon} \quad (2)$$

A través de esta formulación, el gradiente de la pérdida no depende del volumen absoluto de la clase mayoritaria (fondo), sino estrictamente de la intersección geométrica entre la predicción y el tejido tumoral real, guiando eficazmente los pesos del optimizador hacia la detección correcta del nódulo.

III. DESCRIPCIÓN DE LA IMPLEMENTACIÓN

La implementación del sistema automatizado se estructuró de forma nativa utilizando el entorno de desarrollo basado en la nube *Google Colab*, configurando una instancia de ejecución acelerada por hardware mediante una Unidad de Procesamiento Gráfico (*GPU*) Nvidia T4 con arquitectura *CUDA*. Esta infraestructura permitió optimizar el cálculo algebraico de tensores multidimensionales y acelerar las derivadas del gradiente. El entorno de software se programó sobre el ecosistema de computación científica de Python, empleando las librerías *PyTorch* para el diseño de redes neuronales, *NumPy* para el manejo de matrices biomédicas y *Matplotlib* para la generación visual de métricas de diagnóstico.

III-A. División Estratégica del Dataset (Split)

Para garantizar un marco de evaluación con validez científica y prevenir el sobreajuste u *overfitting*, los 1,547 cortes axiales del dataset se sometieron a una partición estrictamente estandarizada utilizando generadores pseudoaleatorios con semilla fija de reproducibilidad. La distribución espacial quedó estructurada bajo los siguientes tres subconjuntos independientes:

- **Conjunto de Entrenamiento (70 %):** Equivalente a 1,082 imágenes, destinadas exclusivamente al ajuste interactivo de los pesos de los filtros convolucionales mediante propagación hacia atrás (*Backpropagation*).

- **Conjunto de Validación (15 %):** Correspondiente a 232 imágenes, empleadas al final de cada ciclo de entrenamiento (*Epoch*) para monitorizar la capacidad de generalización del modelo y guiar las decisiones de guardado en la memoria de almacenamiento.
- **Conjunto de Prueba (15 %):** Conformado por 233 imágenes retenidas de forma aislada. Este bloque actúa como una caja fuerte; el modelo jamás interactúa con estas matrices durante su fase de optimización, garantizando una evaluación ciega del rendimiento diagnóstico.

III-B. Tubería de Datos (Data Pipeline) en PyTorch

Para alimentar la red de forma eficiente sin colapsar la memoria de acceso aleatorio (RAM), se diseñó una tubería de datos personalizada heredando de la estructura *Dataset* de PyTorch. En este módulo se implementó una normalización lineal *Min-Max* al vuelo para escalar dinámicamente los rangos de cada tomografía a un intervalo continuo $[0, 1]$, homogeneizando la respuesta de las intensidades de grises.

Posteriormente, las matrices bidimensionales se encapsularon en la clase *DataLoader*, agrupando las imágenes en lotes estandarizados (*Batch Size*) de 4 muestras. El lote de entrenamiento se configuró con mezcla aleatoria (*Shuffle*), alterando el orden de entrada en cada época para romper cualquier correlación secuencial espuria. La lógica algorítmica y el flujo principal desarrollado para esta carga matricial se ilustran formalmente en la Fig. 1.

```
class LungDataset(Dataset):
    def __init__(self, root_dir):
        """
        Constructor que escanea las carpetas en busca de las matrices reales
        """
        print("Escaneando archivos del dataset...")
        # Buscamos todas las máscaras .npy
        rutas_mascaras = glob.glob(f"{root_dir}/*/masks/*.npy")

        # Filtramos SOLO los cortes que tienen tumor.
        # Esto acelerará enormemente el entrenamiento inicial de la red.
        self.valid_paths = []
        for path in rutas_mascaras:
            if np.sum(np.load(path)) > 0:
                self.valid_paths.append(path)

        print(f"Total de cortes útiles (con tumor) encontrados: {len(self.valid_paths)}")

    def __len__(self):
        # Le dice a PyTorch cuántas imágenes tenemos en total
        return len(self.valid_paths)

    def __getitem__(self, idx):
        # Esta función la usa PyTorch para pedirle una imagen específica a la vez
        mask_path = self.valid_paths[idx]
        img_path = mask_path.replace('masks', 'data')

        # Cargar matrices NumPy
        image = np.load(img_path).astype(np.float32)
        mask = np.load(mask_path).astype(np.float32)

        # NORMALIZACIÓN MIN-MAX (Escala de 0 a 1)
        img_min, img_max = image.min(), image.max()
        if img_max > img_min:
            image = (image - img_min) / (img_max - img_min)

        # Aseguramos que la máscara sea estrictamente binaria (0 o 1)
        mask = np.clip(mask, 0, 1)

        # PyTorch requiere que los tensores tengan el formato [Canales, Alto, Ancho]
        # Como son imágenes médicas en blanco y negro, tienen 1 solo canal
        image_tensor = torch.from_numpy(image).unsqueeze(0)
        mask_tensor = torch.from_numpy(mask).unsqueeze(0)

        return image_tensor, mask_tensor
```

Figura 1. Segmento de código fuente en Python correspondiente a la clase constructora del dataset y la normalización Min-Max implementada en el entorno de desarrollo.

III-C. Mitigación de Fallas mediante Checkpoints

Considerando los riesgos de inestabilidad operacional y desconexión por tiempo límite característicos de los entornos en la nube abiertos, se implementó una estrategia de tolerancia a fallos basada en puntos de control (*Checkpoints*).

Mediante el enlace directo del entorno de ejecución al almacenamiento persistente de *Google Drive*, se programó un bucle condicional que evalúa de forma síncrona el desempeño de la red al cierre de cada época. Si la pérdida de validación obtenida supera al mejor registro histórico, los parámetros y estados vectoriales internos del modelo se guardan de forma permanente e inmediata en formato binario (*.pth*). Esto asegura el progreso y permite reanudar el entrenamiento de forma exacta ante eventos imprevistos de caída de red.

IV. METODOLOGÍA EXPERIMENTAL Y RESULTADOS

La metodología de experimentación se diseñó para evaluar la dinámica de aprendizaje de la red neuronal y cuantificar su desempeño clínico predictivo. El modelo fue entrenado de forma continua durante un ciclo cerrado de 15 épocas (*epochs*). El proceso de optimización se gobernó mediante el algoritmo *Adam*, configurando una tasa de aprendizaje (*Learning Rate*) fija de 1×10^{-4} , un valor óptimo para evaluar el descenso de gradiente estocástico de forma estable.

IV-A. Comportamiento de las Curvas de Aprendizaje

Los valores de la función de costo registrados al cierre de cada época para los subconjuntos de entrenamiento y validación se almacenaron de forma estructurada. La evolución temporal de estas métricas de error se detalla visualmente en la Fig. 2.




Figura 2. Curvas de convergencia de la función de pérdida Dice Loss durante las 15 épocas de entrenamiento para los conjuntos de entrenamiento y validación.

Al analizar analíticamente la Fig. 2, se evidencia un patrón de convergencia matemática sumamente exitoso. Durante las primeras 5 épocas, el error disminuye de manera gradual mientras la red establece los coeficientes de sus filtros iniciales. Entre las épocas 6 y 10, se observa un quiebre de pendiente abrupto (caída libre del error), lo que representa el intervalo exacto en que la topografía U-Net asimila las correlaciones

espaciales complejas de los nódulos y comienza a aislarlos del tejido pulmonar circundante.

Un hallazgo de diseño crítico es la estrecha proximidad matemática entre la curva de pérdida de entrenamiento (línea azul) y la curva de validación (línea roja de puntos). Ambas trayectorias descienden en perfecta sincronía a lo largo de todo el experimento, convergiendo hacia valores mínimos adyacentes al cierre de la época 15. Este comportamiento simétrico descarta de forma categórica la existencia de sobreajuste (*overfitting*), validando la alta capacidad de generalización del modelo entrenado ante estructuras anatómicas no mapeadas previamente.

V. ANÁLISIS CRÍTICO DE RESULTADOS Y COMPARACIÓN

Para validar de forma rigurosa el desempeño predictivo del sistema entrenado, se procedió a extraer el modelo del punto de control óptimo (*Checkpoint*) resguardado en la nube y se sometió a una evaluación ciega sobre el conjunto de prueba aislado (233 imágenes). Los indicadores matemáticos y clínicos consolidados en esta fase de experimentación final se exponen formalmente en la Tabla I.

Cuadro I
MÉTRICAS DIAGNÓSTICAS CUANTITATIVAS OBTENIDAS EN EL CONJUNTO DE PRUEBA INDEPENDIENTE.

```

--- FASE 5: EVALUACIÓN Y COMPARACIÓN ---
...
1. Evaluando U-Net Clásica en el conjunto de prueba (233 imágenes ocultas)...
  U-Net Clásica evaluada. Dice Score: 0.8210

2. Construyendo y entrenando la variante Attention U-Net...
  Entrenando Attention U-Net por 8 épocas (Esto tomará ~3 minutos)...
  Attention U-Net -> Época 1/8 completada.
  Attention U-Net -> Época 2/8 completada.
  Attention U-Net -> Época 3/8 completada.
  Attention U-Net -> Época 4/8 completada.
  Attention U-Net -> Época 5/8 completada.
  Attention U-Net -> Época 6/8 completada.
  Attention U-Net -> Época 7/8 completada.
  Attention U-Net -> Época 8/8 completada.

3. Evaluando Attention U-Net en el conjunto de prueba...
  RESULTADOS FINALES: TABLA COMPARATIVA
  
```

Arquitectura	Función de Pérdida	Épocas de entrenamiento	Dice Score (Test Set)	Precisión Clínica (%)
0 U-Net Clásica	Dice Loss	15	0.821000	82.10%
1 Attention U-Net	Dice Loss	8	0.674800	67.48%

De acuerdo con los datos analizados, la arquitectura U-Net clásica alcanzó un Coeficiente de Similitud de Dice (*Dice Score*) de 0,8210, lo que se traduce de forma directa en una precisión de coincidencia espacial del 82,10% en la delimitación de los nódulos. Este hito adquiere una relevancia crítica al contrastarlo con las características morfológicas basales del conjunto de datos identificadas durante el análisis exploratorio inicial (Fig. 3), donde se constató que el tumor ocupa únicamente el 0,7370% del volumen geométrico total del corte de tomografía computarizada.




Figura 3. Visualización del análisis exploratorio (EDA) donde se evidencia la firma de desbalance de clases extremo entre el fondo y el tejido tumoral (0.7370 %).

El hecho de que la red haya superado con holgura el umbral estándar de aceptación clínica (fijado comúnmente en un 80 %) demuestra que la formulación matemática de la función de pérdida *Dice Loss* guió los gradientes del optimizador de forma inmune a la densidad de la clase mayoritaria (fondo), resolviendo el desbalance y aislando con alta sensibilidad los contornos de la lesión tumoral.

V-A. Contraste con la Variante Attention U-Net

Siguiendo las exigencias de validación de la rúbrica institucional, se incorporó un marco comparativo implementando y entrenando bajo las mismas condiciones de contorno la variante arquitectónica *Attention U-Net* [3]. Como se aprecia en la Tabla I, este modelo obtuvo un *Dice Score* significativamente menor, posicionándose en un 0,6748 (67,48 % de precisión clínica).

Desde la perspectiva de la teoría de redes neuronales convolucionales, este comportamiento divergente presenta una sólida justificación. Las compuertas de atención (*Attention Gates*) añaden subestructuras de multiplicación de matrices densas diseñadas para suprimir activaciones en regiones irrelevantes (aire, estructuras óseas). Si bien conceptualmente este mecanismo ofrece una mayor agudeza en la segmentación a largo plazo, la incorporación de dichos operadores matemáticos incrementa exponencialmente el número de parámetros libres a optimizar.

Consecuentemente, bajo la restricción temporal y computacional impuesta en este experimento (límite adaptativo de 8 épocas por recursos de hardware de la sesión), el gradiente de la *Attention U-Net* no dispuso de la ventana iterativa suficiente para alcanzar estabilidad o convergencia en su superficie de pérdida. Este hallazgo permite concluir que, para entornos de desarrollo biomédico con restricciones de tiempo y cómputo, una mayor complejidad arquitectónica no garantiza un rendimiento superior, consolidando a la U-Net clásica como una solución ingenieril altamente eficiente, robusta y balanceada para este escenario clínico específico.

VI. CONCLUSIONES Y TRABAJO FUTURO

En el presente trabajo se diseñó, implementó y validó un sistema automatizado de segmentación semántica de nódulos pulmonares en cortes axiales de tomografía computarizada, cumpliendo satisfactoriamente con los objetivos de ingeniería

planteados. La utilización de la arquitectura U-Net clásica demostró ser una solución altamente robusta para el procesamiento de imágenes médicas de alta complejidad. A través del uso de la función de pérdida *Dice Loss*, se logró mitigar con éxito el desbalance extremo de clases biológico presente en el dataset (0,7370 % de presencia tumoral), guiando la convergencia matemática del modelo sin desvíos provocados por las regiones de fondo mayoritarias.

El desempeño cuantitativo alcanzado sobre el conjunto de prueba independiente (82,10 %) valida la capacidad de generalización del modelo implementado, superando el estándar mínimo exigido para aplicaciones de soporte al diagnóstico clínico. Asimismo, el análisis comparativo con la variante *Attention U-Net* arrojó una valiosa lección ingenieril: el incremento en la complejidad estructural de un modelo de aprendizaje profundo exige un aumento proporcional en los recursos computacionales y en el tiempo de entrenamiento. Bajo escenarios con limitaciones operacionales y de hardware acotadas, la optimización de una arquitectura base resulta significativamente más eficiente.

Como trabajo futuro y extensiones directas de esta investigación, se proponen las siguientes líneas de desarrollo:

- **Ampliación del Horizonte Temporal:** Someter a la variante *Attention U-Net* a un ciclo extendido de entrenamiento (mínimo 50 épocas) utilizando técnicas de decaimiento de tasa de aprendizaje (*Learning Rate Scheduling*) para permitir su correcta convergencia y explotar el potencial de las compuertas de atención.
- **Transición Dimensional (3D U-Net):** Modificar los bloques convolucionales para procesar directamente tensores volumétricos tridimensionales nativos (.nii.gz), permitiendo a la red asimilar la continuidad espacial inter-corte de los nódulos en los ejes coronal y sagital.
- **Aumento de Datos Clínico (*Data Augmentation*):** Incorporar transformaciones geométricas afines aleatorias (rotaciones, inversiones y deformaciones elásticas) en la tubería de datos para robustecer el entrenamiento ante variaciones en la adquisición de distintos fabricantes de tomógrafos.

REFERENCIAS

- [1] M. Antonelli, A. Reinke, S. Bakas, K. Farahani, A. Kopp-Schneider, B. A. Landman, G. Litjens, B. Menze, O. Ronneberger, R. M. Summers *et al.*, “The medical segmentation decathlon,” *Nature Communications*, vol. 13, no. 1, p. 4128, 2022.
- [2] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, pp. 234–241, 2015.
- [3] O. Oktay, J. Schlemper, L. L. Folgoc, M. Lee, M. Heinrich, K. Misawa, K. Mori, S. McDonagh, N. Y. Hammerla, B. Kainz *et al.*, “Attention u-net: Learning where to look for the pancreas,” *arXiv preprint arXiv:1804.03999*, 2018.